报告：用豆瓣书评训练情感分类器，并应用于《红楼梦》

1. 引言

情感分析是文本分类最典型的应用：给文本自动贴上"正面/负面"标签， 在舆情监测、评论筛选、读者研究中有直接用途。本作业的问题是： **豆瓣读书评论的情感能否由逻辑回归自动识别？用现代书评训练的模型， 应用到 18 世纪的《红楼梦》上，会给出怎样的"情感曲线"？它可信吗？**

选《红楼梦》作应用对象，因为它章回结构清晰（120 回）、情节悲欢起伏明显， 适合检验模型能否捕捉情感的宏观走势；训练语料与应用文本之间 巨大的时代与文体差异，正好用来观察跨域模型的失效方式。

2. 标签与数据

二元问题是"这条评论是正面还是负面"：

标签	含义	操作定义
1（正面）	推荐这本书	豆瓣 5 星评论
0（负面）	不推荐这本书	豆瓣 1 星评论

标签来自评论者自打的星级，属"弱标注"：省去人工标注，但引入噪声 （如反讽的 5 星）。文本单位是一条完整评论；只取 5 星与 1 星两端， 2 - 4 星情感模糊，不使用。

训练数据来自课程提供的 `douban.json`（100,000 条豆瓣评论， 1 - 5 星各 20,000 条），每类随机抽 1,000 条，共 2,000 条，两类完全平衡 （满足每类至少 200 条）。分析文本为《红楼梦》全文（120 回）。

3. 方法

预处理：中文先分词（jieba），去掉单字词、标点与约 80 个常见停用词（"的""了""但是"等），否则它们占据 TF-IDF 高位却无区分能力。

特征：TF-IDF。词频会把"这本书""小说"这类到处出现的词放大， TF-IDF 用 idf = log(N/df) 自动压低它们，突出"精彩""失望" 这类有区分度的词。

切分：按标签分层抽样，80% 训练（1,600 条）、20% 测试（400 条），`random_state=42` 保证可复现；分层保证两集合正负比例相同。 TF-IDF 只在训练集上 fit，测试集仅 transform，避免信息泄漏高估性能。

模型：`sklearn.linear_model.LogisticRegression`。对每条评论算 加权总分 $z = \Sigma w \cdot x + b$，再用 sigmoid 压成正面概率 $p = \sigma(z)$， $p \geq 0.5$ 判正面；w 由交叉熵损失 + 梯度下降学出。

4. 测试集结果

4.1 总体指标

指标	数值
准确率	**0.835**
精确率	0.816
召回率	0.865
F1	0.840

混淆矩阵（400 条测试评论）：

	预测负面	预测正面
实际负面	161	39
实际正面	27	173

模型整体偏向判"正面"（召回率高于精确率）。

4.2 错误分析

66 条错分（`output/misclassified.csv`）中，39 条"真负面被猜成正面"、 27 条"真正面被猜成负面"；被猜成正面的错分平均置信度仅 0.552—— 模型多数只是勉强越过 0.5 的门槛，并不自信。

三个诊断实验（`scripts/04_diagnose.py`）：

猜想	数据	结论
长评论转折多 → 更难	<100 字错误率 18.4%；100–300 字 14.5%	不成立：短评论反而更难（信息少）
含反讽/转折标记词 → 更难	含"呵呵/但是/居然"错误率 20.9%；不含 14.2%	成立：高约 6.7 个百分点
模型只学"书评套路"	去掉最极端 40 词再训练，83.5% → 83.3%	不成立：信号分布在数千词上

三条典型错例（引自错分清单）：

1. 「其实并不如书名所说这是一本独裁的手册 不过很好的介绍了民主和独裁的 政治架构……天下政客一般黑」（真负，猜正，P=0.435）。**先抑后扬再转折**： 词袋丢掉词序后，"很好的介绍"被单独计正分，末句贬义没有强负面词承载， 模型抓不住"整体贬、局部褒"的结构。
2. 「这是我看的第二本痛骂的书……真烂啊！……穿越你妹啊！」 （真负，猜正，P=0.538）。**情绪激烈但情感词稀疏**：骂意全靠语气词和脏话， TF-IDF 里这类口语攻击词权重低，反而被反用的"完美"计了正分。 反讽 + 网络口语，双重失效。
3. 「历史的产物……作者也是没赶上好时候」（真负，猜正，P=0.505）。 **攻击对象从书转向作者**："有市场""水平也还是有一点"这类让步式表述 含大量中性偏正词，贬义藏在"没想明白""看些皮毛"这类需要理解的搭配里。

三条的共同点：**情感由结构（转折、反讽、让步、攻击对象）承载， 而非单个词**——这正是词袋模型的结构性盲区。

4.3 模型学到了什么

最正面的词：人生、世界、生活、喜欢、生命、幸福、感动、活着…… 最负面的词：抄袭、恶心、失望、垃圾、矫情、浪费、看不下去……

正面词多是抽象大词，负面词多是具体抱怨词，符合豆瓣书评的表达习惯： 推荐时谈"人生""生命"，吐槽时用"垃圾""矫情"。这提示模型学到的 可能不只是"情感"，还有书评文体的表达套路——但诊断 C 显示 去掉 40 个极端词后准确率几乎不变，套路词只是冰山一角。

5. 应用：《红楼梦》逐回情感曲线

5.1 结果

把模型应用到 120 回，每回算 P(positive)，见 `output/hlm_predictions.csv` 与曲线图 `output/hlm_sentiment_arc.png`。全书 P 在 **0.355 – 0.596** 之间， 均值 0.470，标准差 0.045，整体略偏负面。最高 3 回：第 98 回（0.596）、 第 120 回（0.585）、第 10 回（0.581）；最低 3 回：第 45 回（0.355）、 第 19 回（0.379）、第 44 回（0.383）。

5.2 解读

域错位诊断：域内中性文本（豆瓣 3 星伪章节）P 均值 0.638， 红楼梦只有 0.470——红楼梦显著低于"域内中性基线"，说明偏负主要来自 域错位（古典白话的用词不在模型的"正面词汇表"里）， 而非小说本身更悲伤（图 `output/diagnosis_domain.png`）。

情节核对（第 78 – 83 回，回目以所用文本版本为准）：

回	P	回目	情节
78	0.537	老学士闲征姽婳词　痴公子杜撰芙蓉诔	晴雯屈死、宝玉作《芙蓉诔》
79	0.500	薛文龙悔娶河东狮　贾迎春误嫁中山狼	迎春误嫁孙绍祖
80	**0.415**	美香菱屈受贪夫棒　王道士胡诌妒妇方	香菱受屈
81	0.450	占旺相四美钓游鱼　奉严词两番入家塾	四美钓游鱼
82	0.496	老学究讲义警顽心　病潇湘痴魂惊恶梦	黛玉惊恶梦
83	0.468	省宫闱贾元妃染恙　闹闺阃薛宝钗吞声	元妃染恙、宝钗受气

第 80 回是这段曲线的最低点，对应香菱受屈的压抑情节—— **低点确实落在情节低谷上**。但第 78 回晴雯之死是全书最悲恸的段落之一， 模型却给了 0.537 的偏正面分数：《芙蓉诔》里大量华丽辞藻 （"花""月""风""玉"）在书评模型里都是正面词。 **华丽 = 正面，这个等式在书评里成立，在悼亡文里完全失效。**

把最高、最低回放回情节里看，这个失效模式更清楚。全书最高分 第 98 回（0.596）正是「苦绛珠魂归离恨天　病神瑛泪洒相思地」—— 黛玉之死，全书最悲恸的段落之一，却因「离恨天」「相思地」这类 诗意辞藻拿了最高分，与第 78 回是同一个失效模式，且更极端。 最低的第 45 回（0.355）是黛玉病中写《秋窗风雨夕》，低分与压抑 情节吻合；但第 19 回（0.379）「情切切良宵花解语」是袭人箴宝玉的 温情日常，也得了低分——模型只学过书评的两端，对小说里 "平淡的温情"同样不敏感。

古诗词密集的章回（如第 27 回葬花吟）会被古典意象词干扰； 词语古今义变化（"风流"在书评里是贬义，在红楼梦里是褒义） 也会让模型误读。此外，小说是叙述性文本，没有书评的 "推荐/不推荐"框架，模型实际在回答一个小说文本 并没有在回答的问题。

6. 反思：限制与改进

数据：训练数据只来自豆瓣单一平台、单一文体，且只取两端—— 任务变简单，模型也没见过"中间地带"。证据：诊断 D 显示域内 3 星 文本被打到 0.638 偏正面，模型对中性的判断已失真。 改进：多平台多文体，纳入 2 - 4 星中评。

标签：星级是代理标签，不是情感判断——恶意打分、反讽 5 星、 随手打分都会成为标签噪声。证据：错分清单里有多条"文字激烈负面、 星级却是 5 星"的评论（如例 2），诊断 B 显示含反讽标记词的评论 错误率高达 20.9%。改进：抽 10% 人工重标估计噪声率， 或用文字情感而非星级作标签。

模型：词袋丢掉词序（"不好"与"好不"同袋），TF-IDF 无法表达 否定、反讽与让步——三条例子都源于此；且模型是域内模型， 应用到 18 世纪古典白话必然系统偏差（红楼梦 0.470 vs 域内中性 0.638）。 改进：用 bigram 保留部分词序（捕捉"不好""不错"）； 用同时期语料（明清白话小说）训练域内模型；或换用中文 BERT 做跨域分析。

结语：这个 83.5% 准确率的分类器在书评域内可用，但它的 《红楼梦》曲线更像一面镜子——照出的既是小说的情感起伏， 也是模型自身的偏见。三个诊断实验说明：短文本比长文本更难、 反讽标记词显著增加错误、套路词并非模型的主要依赖；域错位 实验说明曲线偏负主要来自模型而非小说。数字要读，但更要 带着怀疑读。